

Contextualized Language Model-based Named Entity Recognition in Slovak Texts

supervisor: Mgr. Endre Hamerlik
consultant: Mgr. Marek Šuppa
student: Bc. Dávid Šuba

● Named Entity Recognition (NER)

- recognition and categorization of named entities in text
- Person, Location, Organization, Product, Time
- one of the base tasks in NLP (applications: information extraction from CV, recommender systems...)

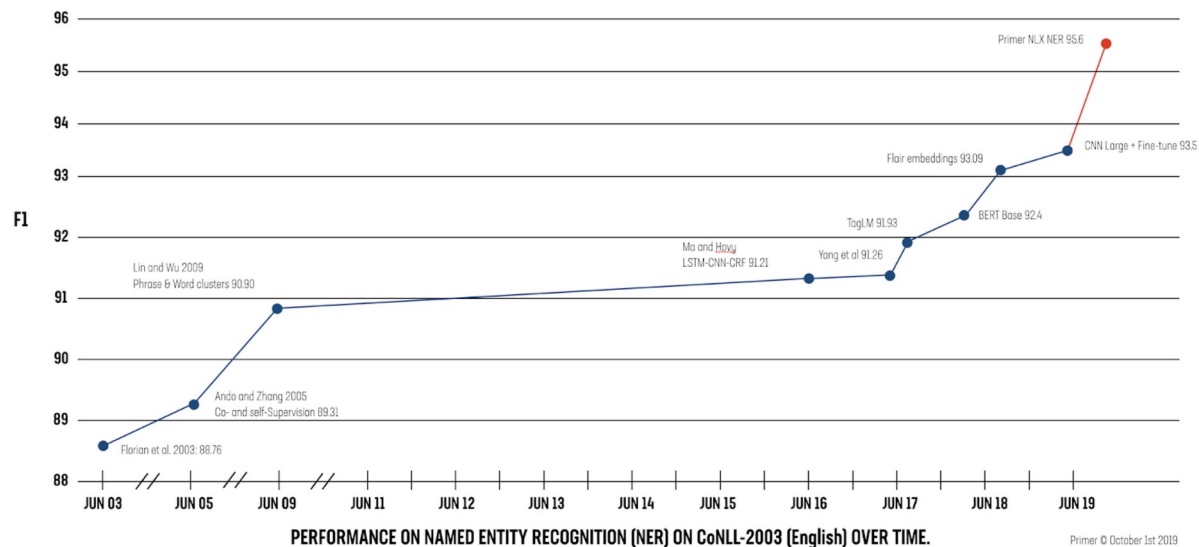
NER DEFINITION

Luke Rawlence PERSON joined Aiimi ORG as a data scientist in Milton Keynes PLACE, after finishing his computer science degree at the University of Lincoln. ORG

source: <https://www.aiimi.com/insights/aiimi-labs-on-named-entity-recognition>

Motivation

- state-of-the-art are contextualized language models based on deep neural networks
- the best systems for NER in slovak texts are rule based and are far behind [1]
- the main reason is lack of resources and datasets



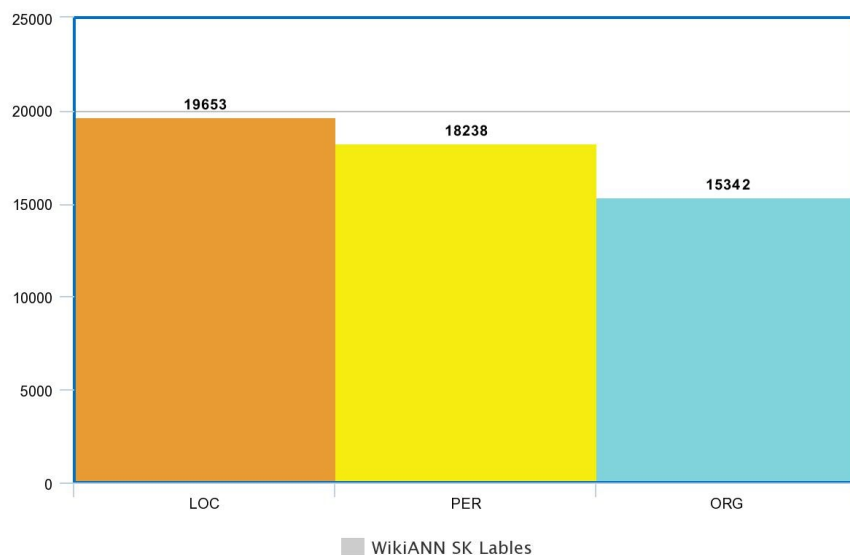
source: <https://company.primer.ai/blog/a-new-state-of-the-art-for-named-entity-recognition/>
www.aiimi.com/insights/aiimi-labs-on-named-entity-recognition

● Goals

- utilize, improve and expand existing slovak NER datasets
- use large multilingual language models and transfer learning for named entity recognition in slovak texts

WikiANN (PAN-X)

- automatically generated 'silver standard' NER dataset for 282 languages from Wikipedia articles [3]
- utilizes markups and knowledge-base links included in articles in cross-lingual tagging
- LOC, PER, ORG tags




Tvorí ho 10 obcí LOC .

rímsky cisár , pozri Konštantín I. (cisár) PER


Highcharts.com

Transformers language models

- BERT (Google), GPT-2/3 (OpenAI), RoBERTa (Facebook), ALBERT (Google)
- deep-learning models with attention layers
- state-of-the-art standard
- trained unsupervised on huge amounts of data
- fine-tuning for specific tasks (transfer learning)



source: <https://venturebeat.com/2020/02/10/microsoft-trains-worlds-largest-transformer-language-model/>



source: [2]

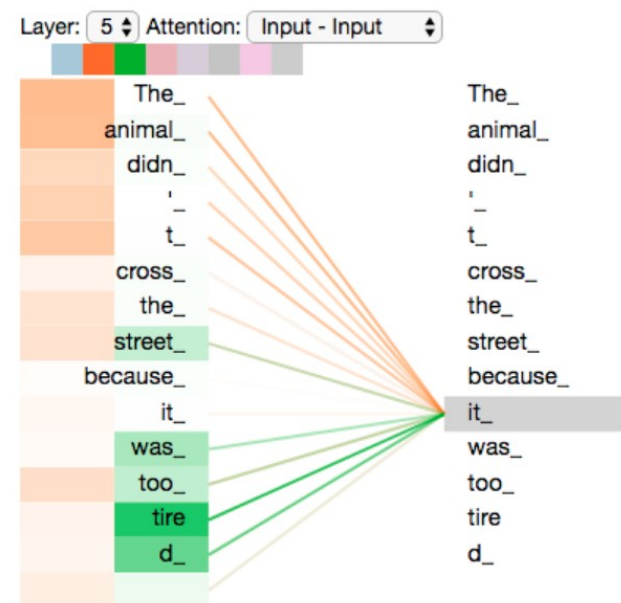
Transformers language models

- attention: the attention-mechanism allows model to decide at each step of sequence which other parts of the sequence are important
- Q - query vector (word in a sequence)
- K - keys (all words in sequence)
- V - values (all words in sequence)

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- positional encoding: allows model to utilize order of sequence

$$PE_{(pos, 2i)} = \sin(pos/10000^{2i/d_{\text{model}}})$$
$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{\text{model}}})$$



source: <http://jalammar.github.io/illustrated-transformer/>

● Trankit + WikiANN

- trankit – python tool for NLP tasks based on transformers
- most pipelines relies at XML-Roberta – big multilanguage model trained at 2.5TB of data from CommonCrawl dataset (<https://commoncrawl.org/>)
- for every language and component (NLP task) is excluded specific adapter (weights across layers), which is after-trained at specific dataset

Precision	Recall	F1
88.9	88.51	88.7

- results at ‘gold’ dataset would be markantly lower

● Trankit + WikiANN

Vláda už minula miliardovú rezervu v rozpočte, ktorá bola určená na krytie výdavkov súvisiacich s pandémiou.

Minister financií a predseda OĽaNO Igor Matovič PER preto predložil návrh na ďalšie zvýšenie výdavkov rozpočtu.

Konkrétne rezerva v rozpočte sa má zvýšiť o 2,4 miliardy eur a nepandemické výdavky sa majú zvýšiť o 984 miliónov.

Napríklad časť peňazí sa má použiť na dofinancovanie železničných spoločností, na výdavky súvisiace s plánom obnovy či na vyššie odvody do rozpočtu EÚ ORG .

Dokopy je to nárast rozpočtových výdavkov v tomto roku o 3,4 miliardy.

Návrh vláda schválila s pripomienkami, problém so zvyšovaním výdavkov majú v SaS ORG .

„Takto sa nedá pristupovať k verejným peniazom, z večera do rána predložiť nejaký dokument a rýchlo schváliť, a nepýtať sa,“ povedal minister hospodárstva Richard Sulík PER .

Návrh nepodporil ani jeho stranícky kolega a minister školstva Branislav Gröhling PER .

Sulík povedal, že proti by hlasoval aj minister zahraničných vecí Ivan Korčok PER , ak by bol na rokovaní vlády prítomný.

„Toto je proti DNA SaS ORG , aby sme tu len takto zvýšili výdavky o 3,5 miliardy eur. Je to vec, ktorú chceme prediskutovať, máme tam mnoho otázok ku konkrétnym položkám.“

Žiada preto riadnu diskusiu a odôvodnenie.

Nejde však o novú informáciu, že deficit sa má v tomto roku zvýšiť na takmer 10 %. Hovorí sa o tom aj v pláne obnovy, ktorý vláda pred dvoma týždňami poslala do Bruselu LOC .

zdroj: www.dennikn.sk

● Spacy (3.0) + WikiANN

- spacy – NLP library focus on production-ready models
- tok2vec + Transition-based parsing

	Precision	Recall	F1
PER	84.80	88.18	86.46
LOC	86.27	84.46	85.36
ORG	81.55	74.65	77.95
	84.49	82.96	83.72

- embeddings from multilingual BERT + Transition-based parsing

	Precision	Recall	F1
PER	95.71	95.52	95.62
LOC	92.16	93.50	92.82
ORG	89.45	86.91	88.10
	92.64	92.33	92.49

● Spacy + WikiANN

Vláda už minula miliardovú rezervu v rozpočte, ktorá bola určená na krytie výdavkov súvisiacich s pandémiou.

Minister financií a predseda **OLaNO** **gor Matovič** **PER** preto predložil návrh na ďalšie zvýšenie výdavkov rozpočtu.

Konkrétne rezerva v rozpočte sa má zvýšiť o 2,4 miliardy eur a nepandemické výdavky sa majú zvýšiť o 984 miliónov.

Napríklad časť peňazí sa má použiť na dofinancovanie železničných spoločností, na výdavky súvisiace s plánom obnovy či na vyššie odvody do rozpočtu **EÚ** **ORG**.

Dokopy je to nárast rozpočtových výdavkov v tomto roku o 3,4 miliardy.

Návrh vláda schválila s pripomienkami, problém so zvyšovaním výdavkov majú v SaS.

„Takto sa nedá pristupovať k verejným peniazom, z večera do rána predložiť nejaký dokument a rýchlo schváliť, a nepýtať sa, **povedal minister hospodárstva** **ORG** **Richard Sulík** **PER** .

Návrh nepodporil ani jeho stranícky kolega a minister školstva **Branislav Gröhling** **PER** .

Sulík povedal, že proti by hlasoval aj minister zahraničných vecí **Ivan Korčok** **PER** , ak by bol na rokovaní vlády prítomný.

„Toto je proti DNA **SaS** **ORG** , aby sme tu len takto zvýšili výdavky o 3,5 miliardy eur. Je to vec, ktorú chceme prediskutovať, máme tam mnoho otázok ku konkrétnym položkám **ORG** . Žiada preto riadnu diskusiu a odôvodnenie.

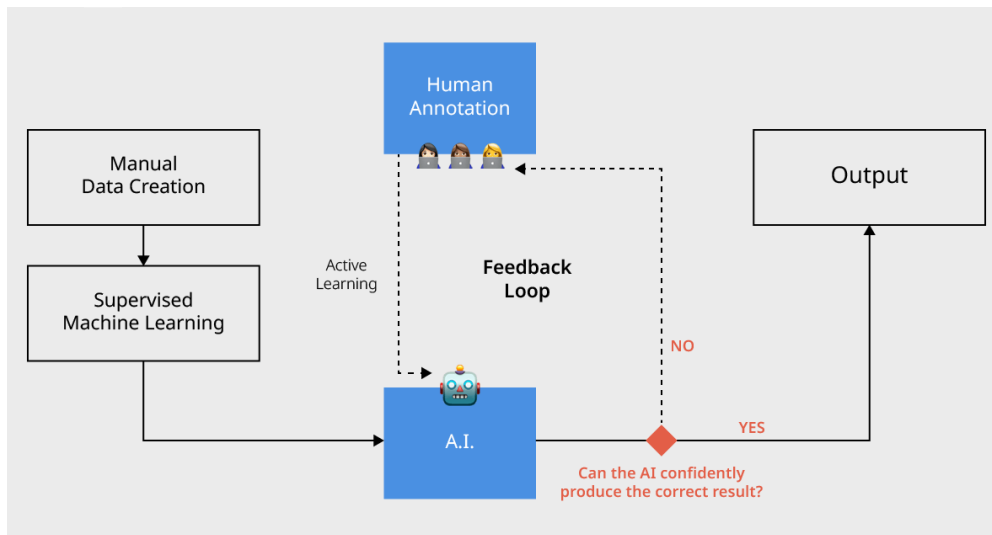
Nejde však o novú informáciu, že deficit sa má v tomto roku zvýšiť na takmer 10 %. Hovorí sa o tom aj v pláne obnovy, ktorý vláda pred dvoma týždňami poslala do **Bruselu** **LOC** :

„V aktuálnom roku sa pri zohľadnení dodatočnej rezervy na krytie vplyvov pandémie až na úrovni 2 % HDP uvažuje s navýšením deficitu na 9,9 % HDP.“

zdroj: www.dennikn.sk

● Human in the loop + Active learning

- annotations which are model uncertain with (or all of them) go to human check
- solution for low resources in slovak NER
- Prodigy (Spacy)



source: <https://lionbridge.ai/articles/what-is-human-in-the-loop-machine-learning/>



source: <https://prodi.gy/>

Dataset Augmentation

- regularly used in various tasks like computer vision (rotation, cropping...) or speech recognition (noise, pace...)
- method used in NLP e.g. back-translation or random deletion/swap/insertion are much harder to use at token level tagged sequential data
- approach proposed at [4] for tasks with token level tags had interesting results and we would like to try it in our case

Lang.	Method	1k	2k	4k	6k	8k	all
en	gold	58.06	67.85	74.55	77.16	80.30	83.04
	+rd*	59.42	67.23	74.51	77.39	80.31	83.39
	+rd	58.97	67.81	74.77	77.35	80.59	83.25
	+gen	61.15	70.61	76.82	79.18	81.02	83.74

source: [2]

● Dataset Augmentation

- Steps:
 - linearization of golden dataset with labels
 - training language model from dataset modified like mentioned
 - generation of syntetic data: language model generates sentence with NER tag (e.g. LOC) after which model can choose from many locations he has seen during training
 - 'de-linearization' of generated sentences

B-PER E-PER O O O O O S-LOC
Jose Valentin has a restaurant business in London

↓ Linearization

B-PER Jose E-PER Valentin has a restaurant business in S-LOC London

source: [4]

● Literatúra

- [1] Kaššák, Ondrej - Kompan, Michal - Bieliková, Mária. Extrakcia pomenovaných entít pre slovenský jazyk. In ZNALOSTI 2012 : Sborník příspěvků 11 ročníku konference, Mikulov, hotel Eliška 14.-16. 10. 2012. Praha:Matfyzpress, 2012, pp. 52-61
- [2] Ashish Vaswani and Noam Shazeer and Niki Parmar and Jakob Uszkoreit and Llion Jones and Aidan N. Gomez and Lukasz Kaiser and Illia Polosukhin. 2017. Attention Is All You Need. arXiv:1706.03762
- [3] Xiaoman Pan, Boliang Zhang, Jonathan May, Joel Nothman, Kevin Knight, and Heng Ji. 2017. Cross-lingual name tagging and linking for 282 languages. In Proceedings of the 55th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), pages 1946-1958
- [4] Bosheng Ding, Linlin Liu, Lidong Bing, Canasai Kruengkrai, Thien HaiNguyen, Shafiq Joty, Luo Si, and Chunyan Miao. 2020. DAGA: Data augmentation with a generation approach for low-resource tagging tasks. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP), pages 6045-6057. Association for Computational Linguistics.

● Key articles

- David Ifeoluwa Adelani et al. 2021. MasakhaNER: Named Entity Recognition for African Languages. arXiv:2103.11811
- Suppa, Marek and Jariabka, Ondrej. 2021. Benchmarking Pre-trained Language Models for Multilingual NER: TraSpaS at the BSNLP2021 Shared Task. In Proceedings of the 8th Workshop on Balto-Slavic Natural Language Processing, pages 105–114, Kiyv, Ukraine. Association for Computational Linguistics.
- Afshin Rahimi, Yuan Li, and Trevor Cohn. 2019. Massively multilingual transfer for ner. arXiv:1902.00193



Thank you for your (self)
attention!